


Die Geometrie der Singulärwertzerlegung

Eine intuitive Herleitung der SVD

Lineare Transformationen: Die Werkzeugkiste


Bevor wir eine Matrix zerlegen, müssen wir verstehen, wie sie den Raum verändert.

1. Skalierung (Strecken/Stauchen)



Findet nur entlang der Hauptachsen statt.


2. Rotation (Drehen)



Verändert den Winkel, aber nicht die Form.


Das einfache Puzzle

Aufgabe: Verwandle den Kreis links in die Ellipse rechts.



Das einfache Puzzle


Aufgabe: Verwandle den Kreis links in die Ellipse rechts.



Lösung: Wir skalieren horizontal/vertikal und rotieren das Ergebnis am Ende.


Das schwierige Puzzle: Die Punkt-Zuordnung

In der Datenanalyse reicht die Form nicht. Wir müssen wissen, **welcher Punkt wohin** wandert.



Das schwierige Puzzle: Die Punkt-Zuordnung

In der Datenanalyse reicht die Form nicht. Wir müssen wissen, **welcher Punkt wohin** wandert.




Wenn wir erst skalieren und dann drehen, landen die Punkte am falschen Ort.

Wir brauchen einen dritten Schritt!

Die Lösung: Die 3 Phasen der SVD


Jede Matrix A lässt sich in drei spezifische geometrische Schritte zerlegen:



1. Startraum


Die Lösung: Die 3 Phasen der SVD

Jede Matrix A lässt sich in drei spezifische geometrische Schritte zerlegen:




Die Lösung: Die 3 Phasen der SVD

Jede Matrix A lässt sich in drei spezifische geometrische Schritte zerlegen:




Die Lösung: Die 3 Phasen der SVD

Jede Matrix A lässt sich in drei spezifische geometrische Schritte zerlegen:



Die Lösung: Die 3 Phasen der SVD

Jede Matrix A lässt sich in drei spezifische geometrische Schritte zerlegen:




$$A = U \cdot \Sigma \cdot V^T$$

Matrix-Anatomie: Schicht für Schicht

Die SVD erlaubt uns, eine Matrix als Summe von Rang-1-Matrizen zu betrachten. Jeder Singulärwert σ_i steuert eine "Informationsschicht" bei.

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_n u_n v_n^T$$




Eine Schicht (Rang 1)

Matrix-Anatomie: Schicht für Schicht

Die SVD erlaubt uns, eine Matrix als Summe von Rang-1-Matrizen zu betrachten. Jeder Singulärwert σ_i steuert eine "Informationsschicht" bei.

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_n u_n v_n^T$$




Die Kraft der Kompression: Das Herz-Beispiel

Ein Bild ist eine Matrix. Schwarze Pixel = 1, weiße Pixel = 0.

Was passiert bei der Rang-Reduktion?

- **Rang 1:** σ_1 fängt die größte Masse ein (ein grauer Block).




Die Kraft der Kompression: Das Herz-Beispiel

Ein Bild ist eine Matrix. Schwarze Pixel = 1, weiße Pixel = 0.

Was passiert bei der Rang-Reduktion?

- **Rang 1:** σ_1 fängt die größte Masse ein (ein grauer Block).
- **Rang 2:** σ_2 fügt die V-Form an der Unterseite hinzu.




Die Kraft der Kompression: Das Herz-Beispiel

Ein Bild ist eine Matrix. Schwarze Pixel = 1, weiße Pixel = 0.

Was passiert bei der Rang-Reduktion?

- **Rang 1:** σ_1 fängt die größte Masse ein (ein grauer Block).
- **Rang 2:** σ_2 fügt die V-Form an der Unterseite hinzu.
- **Rang 3:** Das Herz wird scharf gezeichnet.




Die Kraft der Kompression: Das Herz-Beispiel

Ein Bild ist eine Matrix. Schwarze Pixel = 1, weiße Pixel = 0.


Was passiert bei der Rang-Reduktion?

- **Rang 1:** σ_1 fängt die größte Masse ein (ein grauer Block).
- **Rang 2:** σ_2 fügt die V-Form an der Unterseite hinzu.
- **Rang 3:** Das Herz wird scharf gezeichnet.
- **Rang 4-6:** Fast keine Veränderung ($\sigma \approx 0$).



Die Kraft der Kompression: Das Herz-Beispiel

Ein Bild ist eine Matrix. Schwarze Pixel = 1, weiße Pixel = 0.



Was passiert bei der Rang-Reduktion?

- **Rang 1:** σ_1 fängt die größte Masse ein (ein grauer Block).
- **Rang 2:** σ_2 fügt die V-Form an der Unterseite hinzu.
- **Rang 3:** Das Herz wird scharf gezeichnet.
- **Rang 4-6:** Fast keine Veränderung ($\sigma \approx 0$).

Fazit: Wir können 90% der Matrix wegwerfen und behalten 100% der Bedeutung.

Keine quadratische Matrix? Kein Problem!

Die SVD funktioniert für **jede** $m \times n$ Matrix durch "Null-Padding" in Σ .

The diagram shows the SVD decomposition of a matrix A into three components: U , Σ , and V^T . Matrix A is a 4x4 grid with dimensions $m \times n$. Matrix U is a 4x4 grid with dimensions $m \times m$. Matrix Σ is a 4x4 grid with dimensions $m \times n$, featuring a 3x3 red block on the top-left and the rest of the grid shaded light red, with the word "Nullen" written vertically on the right side. Matrix V^T is a 4x4 grid with dimensions $n \times n$. The matrices are connected by equals and multiplication signs.

$$\begin{matrix} \boxed{A} & = & \boxed{U} & \cdot & \boxed{\Sigma} & \cdot & \boxed{V^T} \\ m \times n & & m \times m & & m \times n & & n \times n \end{matrix}$$

- U : Drehmatrix für den Zielraum ($m \times m$)
- V^T : Drehmatrix für den Startraum ($n \times n$)
- Σ : Streckungsmatrix mit zusätzlicher Dimensionen-Anpassung.