


Singulärwertzerlegung

Singular Value Decomposition (SVD)

Erklärt anhand von Bildkomprimierung

Rotation und Skalierung




Eine **Rotation** ist eine Drehung um einen Winkel.
Eine **Skalierung** streckt oder staucht entlang einer Achse.

Diese beiden Operationen sind die geometrischen Bausteine, mit denen wir gleich eine lineare Abbildung in einfache Schritte zerlegen.

Die Matrixschreibweise kommt später; hier geht es zuerst nur um die sichtbare Wirkung.


Von einer Form zur anderen

Bevor wir Bilder komprimieren, betrachten wir ein Rätsel: Wie kommt man nur durch Rotationen und Skalierungen entlang der Achsen von der linken Grafik zur rechten?




Ausgangsform

lineare Transformation



Zielbild



Rotation, Skalierung, Rotation



$$R_{-90^\circ} = \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix} \quad \Sigma = \begin{pmatrix} 0.45 & 0 \\ 0 & 1 \end{pmatrix} \quad R_{-45^\circ} = \begin{pmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix}$$

Doch was hat das mit SVD zu tun?

Die Idee der SVD



Im Kern ist das das Prinzip der SVD:

$$A = U \Sigma V^T$$


Eine lineare Abbildung wird in drei lesbare Bausteine zerlegt: erst eine Rotation oder Spiegelung, dann eine Skalierung, dann erneut eine Rotation oder Spiegelung.

Unser Ablauf von der vorherigen Folie ist dabei ein **didaktisches Beispiel im Stil der SVD**. Er zeigt das Grundprinzip, ist aber nicht die kanonische SVD, weil die Singulärwerte dort nach Größe sortiert werden und die stärkste Skalierung zuerst steht.

Für dieses Beispiel entsteht die Gesamtmatrix durch Multiplikation:

$$A = R_{-45^\circ} \begin{pmatrix} 0.45 & 0 \\ 0 & 1 \end{pmatrix} R_{-90^\circ} \approx \begin{pmatrix} -0.707 & 0.318 \\ -0.707 & -0.318 \end{pmatrix}$$

Dimensionsreduktion



Warum ist die Zerlegung nützlich, wenn eine einzige Matrix A die Abbildung auch direkt beschreibt?

Der entscheidende Punkt liegt in Σ : Wenn ein Skalierungswert auf 0 gesetzt wird, bleibt eine Richtung erhalten und die andere verschwindet.

Aus einer Fläche wird eine Linie. Genau diese Idee steckt hinter Dimensionsreduktion und später hinter Bildkomprimierung.

Rang-1-Matrix

1	2	3	4
-1	-2	-3	-4
2	4	6	8
10	20	30	40

16 Zahlen

=

1
-1
2
10

·

1	2	3	4
---	---	---	---

8 Zahlen

$$A = uv^T$$

Alle Zeilen sind Vielfache von (1, 2, 3, 4).

Deshalb hat die Matrix Rang 1: 4 Dimensionen, aber nur eine unabhängige Richtung.

Diese Matrix wirkt zuerst wie 16 einzelne Zahlen. Tatsächlich steckt aber viel weniger unabhängige Information darin.

Die Matrix hat also vier Zeilen und vier Spalten, aber nur **eine unabhängige Richtung**. Deshalb ist ihr Rang gleich 1.

Alle Zeilen sind Vielfache der ersten Zeile:

$$(1, 2, 3, 4), \quad -(1, 2, 3, 4), \quad 2(1, 2, 3, 4), \quad 10(1, 2, 3, 4).$$

Statt 16 Zahlen speichern wir nur zwei Vektoren mit insgesamt 8 Zahlen:

$$A = uv^T.$$


Höherer Rang: Summe aus Rang-1-Matrizen

Voller Rang

3	1	4	1
5	9	2	6
5	3	5	8
9	7	9	3

Rang 4

Approximation durch Rang-1-Matrizen



Bei einer Matrix mit Rang 4 sind die Zeilen nicht mehr alle Vielfache voneinander. Die einfache Zerlegung aus der vorherigen Folie reicht dann nicht mehr aus.

Das Grundprinzip bleibt aber gleich: Wir beschreiben die Matrix als Summe mehrerer Rang-1-Matrizen.

$$A \approx \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_k u_k v_k^T$$

Je mehr Bausteine wir addieren, desto genauer wird die Annäherung. Für Kompression speichern wir nur die wichtigsten Bausteine und lassen kleine Beiträge weg.

SVD als Summe von Rang-1-Beiträgen

Die Produktform

$$A = U \Sigma V^T$$

ist gleichbedeutend mit einer Summe aus einzelnen Rang-1-Matrizen:

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_r u_r v_r^T.$$





Bild als Matrix



Bild



255	255	255	150	150	150	150	255	255	255	255	255	255	255	255
255	255	150	150	150	150	150	150	255	255	255	255	255	255	255
255	150	150	150	150	150	150	150	150	255	255	255	255	255	255
255	150	150	150	0	150	150	150	150	255	255	255	255	255	255
80	80	80	150	150	150	150	150	150	255	255	255	255	255	255
255	80	80	150	150	150	150	150	255	255	255	255	255	255	255
255	255	255	150	150	150	150	255	255	255	255	150	150	150	150
255	255	150	150	150	150	150	150	150	150	150	150	150	150	255
255	150	150	150	150	150	150	150	150	150	150	150	150	150	255
255	150	150	150	150	150	150	150	150	150	150	150	255	255	255
255	255	150	150	150	150	150	150	150	150	150	255	255	255	255
255	255	255	150	150	150	150	150	150	255	255	255	255	255	255

Matrixwerte 0 bis 255


Ein Graustufenbild kann als Matrix A verstanden werden: Jeder Eintrag beschreibt den Helligkeitswert eines Pixels. Wenn wir diese Matrix mit der SVD zerlegen,

$$A = U\Sigma V^T,$$

dann sortiert Σ die wichtigsten Bildmuster nach ihrer Stärke.

Für eine Kompression speichern wir nur die größten Singulärwerte und die zugehörigen Vektoren. Dadurch behalten wir die grobe Bildstruktur, müssen aber deutlich weniger Daten speichern.

Einzelne Rang-Beiträge der Ente






Ente als Matrix A

$$A = U\Sigma V^T$$

Die SVD zerlegt die Bildmatrix in einzelne Rang-1-Beiträge.

Jeder Beitrag ist ein Spaltenvektor, ein Singulärwert und ein Zeilenvektor.



Oben steht die SVD-Zerlegung der Bildmatrix:

$$A = U\Sigma V^T.$$

Unten sind einzelne Rang-Beiträge der Ente zu sehen. Jeder Beitrag besteht aus einem Vektor aus U , einem Singulärwert aus Σ und einem Vektor aus V^T .

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$$

Wichtig: Die kleinen Enten unten sind **nicht aufsummiert**, sondern zeigen jeweils nur den einzelnen Beitrag eines Rangs.


Rang-k-Näherung der Ente

Bei einem Bild ist A die Matrix der Pixelwerte.

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T.$$

Mit jedem Rang kommt ein weiteres Muster dazu. Kleine Ränge speichern wenig, verlieren aber Details; größere Ränge nähern sich der Originalmatrix an.

Rang $k = 1$  27 statt 169 Zahlen



Rang-k-Näherung von Albert Einstein

Das gleiche Prinzip funktioniert auch für ein echtes Graustufenbild:


$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T.$$

Hier wird das Einstein-Bild aus der hochauflösenden Vorlage als Matrix zerlegt. Kleine Ränge zeigen zuerst die grobe Struktur; höhere Ränge ergänzen Details, Kanten und feine Kontraste.

Rang $k = 1$




Original



1344 statt 445800 Zahlen

Rekonstruktion



Von der Matrix zur SVD

Die SVD kann man auf zwei gleichwertige Arten lesen:

$$A = U \Sigma V^T$$

oder als Summe einzelner Rang-1-Bausteine:

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T.$$

Mini-Beispiel:

$$A = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix} = \begin{pmatrix} 1 \\ 2 \end{pmatrix} \begin{pmatrix} 1 & 2 \end{pmatrix}$$

Das ist ein einzelner Rang-1-Baustein. Bei Bildern addieren wir viele solcher Bausteine.

Wie findet man aus einer Pixelmatrix wie der Ente eigentlich die drei Matrizen U , Σ und V^T ?

Herleitung: Was suchen wir?

Für eine Matrix $A \in \mathbb{R}^{m \times n}$ suchen wir

$$A = U \Sigma V^T,$$

wobei U und V orthogonale Matrizen sind und Σ nur auf der Diagonalen Einträge hat.

U

orthogonale Richtungen im Zielraum

Σ

Stärken der einzelnen Richtungen

V^T

orthogonale Richtungen im Eingaberaum

Die Frage ist also nicht, ob so eine Zerlegung nützlich ist, sondern wie wir diese Richtungen und Stärken systematisch aus A berechnen.

Schritt 1: Eingaberichtungen finden

Wir betrachten zuerst

$$A^T A.$$

Diese Matrix hat zwei wichtige Eigenschaften:

1. Sie ist symmetrisch: $(A^T A)^T = A^T A$.
2. Sie ist positiv semidefinit:

$$x^T A^T A x = \|Ax\|^2 \geq 0.$$

Symmetrische Matrizen haben orthogonale Eigenvektoren. Deshalb wählen wir die Spalten von V als Eigenvektoren von $A^T A$:

$$A^T A v_i = \lambda_i v_i.$$

Diese v_i sind die Eingaberichtungen, also die Richtungen, die vor der Skalierung betrachtet werden.

Schritt 2: Singulärwerte

Weil

$$x^T A^T A x = \|Ax\|^2 \geq 0,$$

sind alle Eigenwerte von $A^T A$ nichtnegativ:

$$\lambda_i \geq 0.$$

Daraus definieren wir die Singulärwerte:

$$\sigma_i = \sqrt{\lambda_i}.$$

Die Singulärwerte stehen in Σ auf der Diagonalen:

$$\Sigma = \begin{pmatrix} \sigma_1 & 0 & \dots \\ 0 & \sigma_2 & \dots \\ \vdots & \vdots & \ddots \end{pmatrix}.$$

Große σ_i bedeuten: Diese Richtung trägt viel zur Matrix bei.
Kleine σ_i können wir für eine Rang- k -Näherung weglassen.

Schritt 3: Zielrichtungen berechnen

Wenn v_i eine Eingaberichtung ist, dann zeigt Av_i , wohin diese Richtung durch A abgebildet wird.

Die Länge dieses Bildes ist der Singulärwert:

$$\|Av_i\| = \sigma_i.$$

Für $\sigma_i > 0$ normieren wir deshalb:

$$u_i = \frac{1}{\sigma_i} Av_i.$$

Damit gilt für jede wichtige Richtung:

$$Av_i = \sigma_i u_i.$$

Schreibt man alle Richtungen gleichzeitig als Matrizen, erhält man:

$$AV = U\Sigma.$$

Multiplikation mit V^T liefert die SVD:

$$A = U\Sigma V^T.$$

Rechenweg für eine Bildmatrix

1. Pixelmatrix A aufstellen.
2. $A^T A$ berechnen.
3. Eigenvektoren von $A^T A$ bestimmen. Diese bilden V .
4. Singulärwerte berechnen: $\sigma_i = \sqrt{\lambda_i}$.
5. Zielrichtungen berechnen: $u_i = \frac{1}{\sigma_i} A v_i$.

Danach haben wir

$$A = U \Sigma V^T \quad \text{und} \quad A_k = \sum_{i=1}^k \sigma_i u_i v_i^T.$$

Für echte Bilder wird dieser Prozess numerisch berechnet. Mathematisch passiert aber genau das: Wir finden Richtungen, ordnen sie nach Stärke und behalten für die Kompression nur die wichtigsten.

Mini-Beispiel: Rang 1

Nehmen wir

$$A = \begin{pmatrix} 1 & 2 \\ 2 & 4 \end{pmatrix}.$$

Dann ist

$$A^T A = \begin{pmatrix} 5 & 10 \\ 10 & 20 \end{pmatrix}.$$

Die Eigenwerte sind

$$\lambda_1 = 25, \quad \lambda_2 = 0.$$

Also sind die Singulärwerte

$$\sigma_1 = 5, \quad \sigma_2 = 0.$$

Ein passender Eigenvektor ist

$$v_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$$

Daraus folgt

$$u_1 = \frac{1}{5} A v_1 = \frac{1}{\sqrt{5}} \begin{pmatrix} 1 \\ 2 \end{pmatrix}.$$

Damit besteht A aus einem einzigen Rang-1-Beitrag:

$$A = 5 u_1 v_1^T.$$