


Singulärwertzerlegung

Singular Value Decomposition (SVD)

Erklärt anhand von Bildkomprimierung

Rotation und Skalierung




Eine **Rotation** ist eine Drehung um einen Winkel.
Eine **Skalierung** streckt oder staucht entlang einer Achse.

Diese beiden Operationen sind die geometrischen Bausteine, mit denen wir gleich eine lineare Abbildung in einfache Schritte zerlegen.

Die Matrixschreibweise kommt später; hier geht es zuerst nur um die sichtbare Wirkung.


Von einer Form zur anderen

Bevor wir Bilder komprimieren, betrachten wir ein Rätsel: Wie kommt man nur durch Rotationen und Skalierungen entlang der Achsen von der linken Grafik zur rechten?




Ausgangsform

lineare Transformation



Zielbild


Rotation, Skalierung, Rotation



$$R_{-90^\circ} = \begin{pmatrix} 0 & 1 \\ -1 & 0 \end{pmatrix} \quad \Sigma = \begin{pmatrix} 0.45 & 0 \\ 0 & 1 \end{pmatrix} \quad R_{-45^\circ} = \begin{pmatrix} \frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \\ -\frac{\sqrt{2}}{2} & \frac{\sqrt{2}}{2} \end{pmatrix}$$

Doch was hat das mit SVD zu tun?

Die Idee der SVD



R_{-90° $\begin{bmatrix} 0 & 1 \\ -1 & 0 \end{bmatrix}$	Σ $\begin{bmatrix} 0.45 & 0 \\ 0 & 1 \end{bmatrix}$	R_{-45° $\begin{bmatrix} 0.71 & 0.71 \\ -0.71 & 0.71 \end{bmatrix}$
--	---	--

Im Kern ist das das Prinzip der SVD:

$$A = U \Sigma V^T$$


Eine lineare Abbildung wird in drei lesbare Bausteine zerlegt: erst eine Rotation oder Spiegelung, dann eine Skalierung, dann erneut eine Rotation oder Spiegelung.

Unser Ablauf von der vorherigen Folie ist dabei ein **didaktisches Beispiel im Stil der SVD**. Er zeigt das Grundprinzip, ist aber nicht die kanonische SVD, weil die Singulärwerte dort nach Größe sortiert werden und die stärkste Skalierung zuerst steht.

Für dieses Beispiel entsteht die Gesamtmatrix durch Multiplikation:

$$A = R_{-45^\circ} \begin{pmatrix} 0.45 & 0 \\ 0 & 1 \end{pmatrix} R_{-90^\circ} \approx \begin{pmatrix} -0.707 & 0.318 \\ -0.707 & -0.318 \end{pmatrix}$$

Dimensionsreduktion



$$\underbrace{\begin{pmatrix} 3 & 0 \\ 0 & 2 \end{pmatrix}}_{\Sigma} \underbrace{\begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix}}_{\text{Punkte}} = \begin{pmatrix} 6 & 3 \\ 2 & 4 \end{pmatrix} \quad \underbrace{\begin{pmatrix} 3 & 0 \\ 0 & 0 \end{pmatrix}}_{\Sigma (\sigma_2 = 0)} \begin{pmatrix} 2 & 1 \\ 1 & 2 \end{pmatrix} = \begin{pmatrix} 6 & 3 \\ 0 & 0 \end{pmatrix}$$

Links hat Σ die **Singulärwerte** $\sigma_1 = 3$, $\sigma_2 = 2$ — die **Punkte** (je Spalte einer) bleiben in der Fläche. Rechts ist $\sigma_2 = 0$: die ganze y-Zeile wird 0, alle Punkte landen auf der Linie $y = 0$.

In der SVD $A = U \Sigma V^T$ steckt die ganze Streckung in Σ : dort stehen die **Singulärwerte** $\sigma_1 \geq \sigma_2 \geq \dots \geq 0$.

Sie bestimmen die Streckung jeder Richtung. Setzt man den **kleinsten Singulärwert** auf 0, entfällt die unwichtigste Richtung.

Genau das ist Dimensionsreduktion: kleine Singulärwerte weglassen. Dieselbe Idee trägt später die Bildkompression.

Rang-1-Matrix

1	2	3	4
-1	-2	-3	-4
2	4	6	8
10	20	30	40

16 Zahlen

=

1
-1
2
10

.

1	2	3	4
---	---	---	---

8 Zahlen

$$A = uv^T$$

Alle Zeilen sind Vielfache von (1, 2, 3, 4).

Deshalb hat die Matrix Rang 1: 4 Dimensionen, aber nur eine unabhängige Richtung.

Diese Matrix wirkt zuerst wie 16 einzelne Zahlen. Tatsächlich steckt aber viel weniger unabhängige Information darin.

Die Matrix hat also vier Zeilen und vier Spalten, aber nur **eine unabhängige Richtung**. Deshalb ist ihr Rang gleich 1.


Alle Zeilen sind Vielfache der ersten Zeile:

(1, 2, 3, 4), -(1, 2, 3, 4), 2(1, 2, 3, 4), 10(1, 2, 3, 4).

Statt 16 Zahlen speichern wir nur zwei Vektoren mit insgesamt 8 Zahlen:

$$A = u v^T.$$

Höherer Rang: Summe aus Rang-1-Matrizen



$$A_k = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_k u_k v_k^T$$

Bei einer Matrix mit Rang 4 sind die Zeilen nicht mehr alle Vielfache voneinander. Die einfache Zerlegung aus der vorherigen Folie reicht dann nicht mehr aus.

Das Grundprinzip bleibt aber gleich: Wir beschreiben die Matrix als Summe mehrerer Rang-1-Matrizen.

$$A_k = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \dots + \sigma_k u_k v_k^T$$

Für $k = r$ ist das die vollständige Zerlegung. Für $k < r$ entsteht eine Näherung: Je mehr Bausteine wir addieren, desto genauer wird sie. Für Kompression speichern wir nur die wichtigsten Bausteine und lassen kleine Beiträge weg.


SVD als Summe von Rang-1-Beiträgen

Die Produktform

$$A = U \Sigma V^T$$

ist gleichbedeutend mit einer Summe aus einzelnen Rang-1-Matrizen:

$$A = \sigma_1 u_1 v_1^T + \sigma_2 u_2 v_2^T + \cdots + \sigma_r u_r v_r^T.$$



SVD-Rang-1-Zerlegung

Dieselbe Zerlegung in zwei Sichtweisen: oben als **Produkt** $A = U\Sigma V^T$, unten als **Summe** einzelner Rang-1-Beiträge $\sigma_i u_i v_i^T$.





Bild als Matrix



Bild



255	255	255	150	150	150	150	255	255	255	255	255	255
255	255	150	150	150	150	150	150	255	255	255	255	255
255	150	150	150	150	150	150	150	150	255	255	255	255
255	150	150	150	0	150	150	150	150	255	255	255	255
80	80	80	150	150	150	150	150	150	255	255	255	255
255	80	80	150	150	150	150	150	255	255	255	255	255
255	255	255	150	150	150	150	255	255	255	255	150	150
255	255	150	150	150	150	150	150	150	150	150	150	150
255	150	150	150	150	150	150	150	150	150	150	150	255
255	150	150	150	150	150	150	150	150	150	150	255	255
255	255	150	150	150	150	150	150	150	150	255	255	255
255	255	255	150	150	150	150	150	150	255	255	255	255

Matrixwerte 0 bis 255

Bis hierhin haben wir Matrizen als Summen von Rang-1-Beiträgen betrachtet. Jetzt wenden wir genau diese Idee auf ein Bild an.

Ein Graustufenbild ist nichts anderes als eine Matrix A : Jeder Eintrag ist ein Pixelwert zwischen 0 und 255.


$$A = U\Sigma V^T,$$

zerlegt diese Pixelmatrix in geordnete Bildbausteine.

Die größten Singulärwerte beschreiben die wichtigsten Strukturen der Ente. Für die Kompression speichern wir nur diese stärksten Beiträge und lassen kleinere Details weg.


Auf der nächsten Folie sieht man diese Beiträge einzeln.

SVD der Entenmatrix: erster Rang-1-Beitrag



Rang-1-Beiträge der Ente

Jeder Rang-1-Beitrag: das Bild und direkt darunter die Zerlegung $\sigma_i u_i v_i^T$



Rang-k-Näherung der Ente


Bei einem Bild ist A die Matrix der Pixelwerte.

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T.$$


Mit jedem Rang kommt ein weiteres Muster dazu. Kleine Ränge speichern wenig, verlieren aber Details; größere Ränge nähern sich der Originalmatrix an.

Rang $k = 1$  27 statt 169 Zahlen

Original



Rekonstruktion



Rang-k-Näherung von Albert Einstein

Bei einem hochauflösten Bild wird die Pixelmatrix deutlich größer. Ein Originalbild mit m Zeilen und n Spalten speichert ungefähr $m \cdot n$ Helligkeitswerte.


Original: $m \cdot n$ Rang- k : $k(m + n + 1)$

Bei hoher Auflösung lohnt sich diese Speicherung stärker: Für kleine k behalten wir nur wenige wichtige Bildmuster, sparen aber sehr viele Pixelwerte ein.


Je höher wir k wählen, desto mehr Details, Kanten und feine Kontraste kommen zurück. Gleichzeitig steigt aber auch die Datenmenge wieder.

Rang $k = 1$  1344 statt 445800 Zahlen

Original



Rekonstruktion



Was war beim Einstein-Bild überraschend?

Beim Einstein-Bild haben wir gesehen:

- Schon wenige Terme liefern eine erkennbare Rekonstruktion.
- Viele Bildinformationen können weggelassen werden.
- Trotzdem bleibt die grobe Struktur des Bildes erhalten.

$$A_k = \sum_{i=1}^k \sigma_i \mathbf{u}_i \mathbf{v}_i^T$$

Dabei behalten wir nur die ersten k Bildbausteine.

Das funktioniert nur, wenn die Bausteine vorher nach Wichtigkeit geordnet wurden: Die ersten Bausteine müssen die stärksten Bildanteile enthalten.

Wie findet die SVD solche wichtigen Bausteine?

Ein Bild als Summe einfacher Bausteine

Ein Bild als Matrix $A \in \mathbb{R}^{m \times n}$ enthält $m \cdot n$ Pixelwerte.

Für Kompression wollen wir das Bild nicht als einzelne Pixelwerte betrachten, sondern als Summe einfacher Bildanteile:

$$A \approx B_1 + B_2 + \dots + B_k.$$


Dabei soll gelten:

- B_1 : wichtigster grober Bildanteil
- B_2 : nächster wichtiger Anteil
- ...
- nach k Anteilen stoppen wir


Jeder Baustein soll also eine einfache Struktur erklären: zuerst grobe, starke Anteile, später feinere Details.

Was steckt in einem einzelnen solchen Baustein?


einzelne Bildbausteine



+




+



=

überlagerte Summe




Was steckt in einem einzelnen SVD-Baustein?

Wir greifen den wichtigsten Baustein aus der vorherigen Folie heraus: den vertikalen Anteil.
Für das Prinzip verwenden wir hier den kleinen Baustein aus Folie 17. Beim echten Bild hätten u_i und v_i entsprechend viele Einträge wie Bildzeilen und Bildspalten.

1. Baustein aus Folie 17

Baustein 1

$\sigma_1 u_1 v_1^T$



vertikaler Anteil

Die Form ist schon sichtbar:
außen hell, Mitte dunkel.

2. Zerlegung in Vektoren

u_1 Höhenverteilung

1
1
1
1
0
0

v_1^T Spaltenmuster

0	0	1	1	0	0
---	---	---	---	---	---

$\times$

wi

v_1^T sagt: außen 0, Mitte 1.
 u_1 sagt: nur in den oberen Zeilen.

3. Äußeres Produkt

$u_1 v_1^T$

legt die Form fest

0	0	1	1	0	0
0	0	1	1	0	0
0	0	1	1	0	0
0	0	1	1	0	0
0	0	0	0	0	0
0	0	0	0	0	0

Jede Zeile enthält dasselbe
Muster über die Spalten.

Das äußere Produkt macht
wieder eine 2D-Matrix.

4. Wirkung von σ_1

σ_1 skaliert den Baustein

gleiche Form, andere Sichtbarkeit
klein mittel groß



schwach sichtbar dominant

$B_1 = \sigma_1 \cdot (u_1 v_1^T)$

σ_1 verändert nicht die Form,
sondern skaliert den Baustein.


Singulärwert $\times$ Form = Bildbaustein

Zur Veranschaulichung verwenden wir hier 0/1-Werte. In der echten SVD sind u_i und v_i normierte Vektoren.

$u_1 v_1^T$ legt die **Form** fest. σ_1 ist der **Singulärwert** dieses Bausteins; anschaulich bestimmt er seine Stärke.
Die nächste Frage ist: Welche dieser Bausteine sind stark genug, um zuerst gespeichert zu werden?

Wie vermeiden wir doppelte Muster?

Jede Schicht soll einen eigenen Anteil des Bildes erklären. Wenn zwei Schichten fast dasselbe Muster enthalten, wäre die Zerlegung redundant: dieselbe Struktur würde mehrfach gespeichert.



Für Kompression wollen wir aber, dass jeder gespeicherte Baustein wirklich neue Information bringt.

Mathematisch heißt das:

$$v_i^T v_j = 0 \quad \text{für } i \neq j,$$

Die Muster über die Spalten haben keinen gemeinsamen Anteil im Sinne des Skalarprodukts.

$$u_i^T u_j = 0 \quad \text{für } i \neq j.$$

Die Höhenverteilungen haben keinen gemeinsamen Anteil.

Orthogonal heißt hier nicht räumlich getrennt. Die Schichten können an denselben Bildstellen wirken. Orthogonal heißt: Als normierte Vektoren enthalten sie keine gemeinsame Richtung, deshalb zählt man dieselbe Struktur nicht doppelt. **Jeder Baustein bringt eine neue unabhängige Bildschicht.**

Wie finden wir nun starke Muster, die gleichzeitig unabhängig sind?

Wie finden wir starke und unabhängige Muster?

Aus den letzten Folien wissen wir: Ein guter SVD-Baustein soll zwei Bedingungen erfüllen:

1. **stark:**
Er soll viel sichtbare Bildinformation erklären.
2. **unabhängig:**
Er soll nicht dasselbe Muster speichern wie ein anderer Baustein.

Ein kompletter Baustein hat die Form

$$B_i = \sigma_i u_i v_i^T.$$

Um ihn zu finden, starten wir mit einem Teil davon:


$$v \in \mathbb{R}^n$$

v ist ein mögliches **Muster über die Spalten**.

Die nächste Frage lautet:

Wie messen wir, wie stark dieses Spaltenmuster (v) im Bild (A) vorkommt?

Bildbaustein



$$B_i = \sigma_i u_i v_i^T$$

später folgen σ_i und Höhenverteilung

Suche starten bei v

0	0	1	1	0	0
---	---	---	---	---	---

Muster über die Spalten
vereinfachtes 0/1-Beispiel

Was bedeutet (Av) ?

Um zu messen, wie stark ein Spaltenmuster v im Bild vorkommt, wenden wir A auf dieses Muster an:

$$Av$$

Dabei gilt:

$$v \in \mathbb{R}^n \quad Av \in \mathbb{R}^m.$$


Also: v hat einen Wert pro Bildspalte, Av einen Wert pro Bildzeile.

Für die j -te Bildzeile gilt:

$$(Av)_j = \text{Zeile}_j(A) \cdot v$$

Jede Bildzeile wird also per Skalarprodukt mit dem Spaltenmuster v verglichen. Passt das Muster gut zu einer Zeile, wird der Wert groß. Passt es kaum, wird der Wert klein. Damit ist Av die **Höhenantwort** des Bildes auf das Spaltenmuster.

Bildbaustein aus Folie 20 als Matrix A



vereinfachtes 0/1-Beispiel

0	0	1	1	0	0
0	0	1	1	0	0
0	0	1	1	0	0
0	0	1	1	0	0
0	0	0	0	0	0
0	0	0	0	0	0

Spaltenmuster v

0
0
1
1
0
0

zeilenweise Rechnung

$$\begin{aligned} 001100 \cdot v &= 2 \\ 001100 \cdot v &= 2 \\ 001100 \cdot v &= 2 \\ 001100 \cdot v &= 2 \\ 000000 \cdot v &= 0 \\ 000000 \cdot v &= 0 \end{aligned}$$

Höhenantwort Av

2
2
2
2
0
0

zeigt den Wert je Bildzeile

Die Höhenantwort Av zeigt, wie stark das Spaltenmuster in jeder Bildzeile vorkommt. Ihre Länge misst die Gesamtstärke:

$$\|Av\| = \sqrt{2^2 + 2^2 + 2^2 + 2^2 + 0^2 + 0^2} = 4.$$

Je größer $\|Av\|$, desto stärker ist die Antwort des Bildes auf das Muster v . Damit wird unsere Suche konkret:

$$\max_{\|v\|=1} \|Av\|.$$

Wir suchen das normierte Spaltenmuster, das die stärkste Höhenantwort erzeugt. Im Beispiel verwenden wir 0/1-Werte. Für die eigentliche Suche normieren wir v auf $\|v\| = 1$, damit alle Spaltenmuster gleich lang sind und $\|Av\|$ nur die Antwort des Bildes auf dieses Muster misst – nicht eine künstliche Skalierung von v .

Warum können wir A nicht direkt verwenden?

Wir haben jetzt eine Suchfrage:

$$\max_{\|v\|=1} \|Av\|.$$

Dafür wäre der Spektralsatz hilfreich, weil er orthogonale Richtungen liefert.

Für eine symmetrische Matrix S gilt:

$$S = Q\Lambda Q^T, \quad Sq_i = \lambda_i q_i.$$

Die Spalten von Q sind orthogonale Richtungen. In unserer SVD-Herleitung werden die zugehörigen Eigenwerte später zu Quadraten der Singulärwerte.

Aber der Spektralsatz gilt für symmetrische quadratische Matrizen.

Unsere Bildmatrix ist im Allgemeinen

$$A \in \mathbb{R}^{m \times n}$$

und damit oft rechteckig. Außerdem ist sie meist nicht symmetrisch:

$$A^T \neq A.$$

Anschaulich passiert bei A :

$$A : \mathbb{R}^n \rightarrow \mathbb{R}^m.$$

Ein Spaltenmuster v wird zu einer Höhenantwort Av .

Der Spektralsatz braucht dagegen eine symmetrische quadratische Matrix, die einen Vektor wieder in denselben Raum abbildet.

Bildmatrix A

$$A: \mathbb{R}^n \rightarrow \mathbb{R}^m$$

Spaltenmuster v



A

Höhenantwort Av



anderer Raum

kein direktes Eigenwertproblem

Spektralsatz S

$$S: \mathbb{R}^n \rightarrow \mathbb{R}^n$$

Muster v



S

gleicher Raum



$$Sv = \lambda v$$

gleiche Richtung, nur skaliert

Warum führt die Normmessung zu $A^T A$?

Unsere Suchfrage war:

$$\max_{\|v\|=1} \|Av\|.$$

Da $\|Av\| \geq 0$, dürfen wir stattdessen die quadrierte Norm maximieren:

$$\max_{\|v\|=1} \|Av\|^2.$$

Das ändert nicht, welches Muster gewinnt. Beispiel: Aus $4 > 2$ wird $16 > 4$. Die Reihenfolge bleibt gleich.

Der Vorteil: Die quadrierte Länge kann als Skalarprodukt geschrieben werden:


$$\begin{aligned}\|Av\|^2 &= (Av)^T (Av) \\ &= v^T A^T A v.\end{aligned}$$

Der entscheidende Schritt ist:

$$(Av)^T = v^T A^T.$$

Dadurch erscheint zwischen den beiden v -Termen automatisch $A^T A$.

Höhenantwort Av



Länge²



$$\|Av\|^2$$

als Skalarprodukt



$$(Av)^T (Av)$$

$$(Av)^T = v^T A^T$$



$$v^T \boxed{A^T A} v$$

Bewertungszahl für genau dieses v

Aha-Schritt

$$(Av)^T (Av) = v^T A^T A v$$

v bleibt der getestete Kandidat; $A^T A$ ist die feste Bewertungsmatrix.

Ausblick: Kandidaten bewerten

$v_1 \rightarrow 16$ $v_2 \rightarrow 4$ $v_3 \rightarrow 1$
größter Wert gewinnt

Für ein festes Spaltenmuster v ist $v^T A^T A v$ genau dieselbe Zahl wie $\|Av\|^2$: die quadrierte Norm der Höhenantwort im Originalbild. $A^T A$ ist die Bewertungsmatrix. Die äußeren v -Terme markieren den Kandidaten, der gerade getestet wird.

Warum löst $A^T A$ unser Suchproblem?

Aus der letzten Folie wurde unsere Suche:

$$\max_{\|v\|=1} \|Av\|^2 = \max_{\|v\|=1} v^T A^T A v.$$

Damit suchen wir nicht mehr direkt in der Höhenantwort Av , sondern bewerten jedes Spaltenmuster v mit $A^T A$.

Wichtig: $A^T A$ ersetzt nicht das Bild A . Es ist die Bewertungsmatrix für die Spaltenmuster.

Jetzt passt $A^T A$ zum Spektralsatz:


$$A^T A \in \mathbb{R}^{n \times n}$$

Start und Ziel liegen wieder im Spaltenmuster-Raum.

Außerdem ist $A^T A$ symmetrisch:

$$(A^T A)^T = A^T A.$$

Für solche Matrizen liefert der Spektralsatz orthogonale Eigenrichtungen.



Brücke: Aus der Bewertungsmatrix wird ein Spektralsatz-Problem. Erst danach erhalten wir die orthogonalen Spaltenmuster.

Der Spektralsatz liefert die gesuchten Muster

Unsere Suche lautet jetzt:

$$\max_{\|v\|=1} v^T A^T A v.$$

Wir suchen also normierte Spaltenmuster v , die von $A^T A$ möglichst stark bewertet werden.

Da $A^T A$ symmetrisch ist, dürfen wir den Spektralsatz anwenden.

Er liefert Eigenvektoren:

$$A^T A v_i = \lambda_i v_i.$$

Die Eigenvektoren v_i sind die gesuchten **Spaltenmuster**.

Das bedeutet: $A^T A$ verändert die Richtung v_i nicht, sondern skaliert sie nur mit λ_i . Solche Richtungen sind stabile Muster der Bewertungsmatrix.

Der Spektralsatz liefert genau das, was wir brauchen:

1. Unabhängige Spaltenmuster

$$v_i^T v_j = 0 \quad (i \neq j)$$

Die Muster speichern keine doppelte Richtung.

2. Sortierbare Eigenwerte

$$\lambda_1 \geq \lambda_2 \geq \dots \geq 0$$

Die ersten v_i gehören zu den größten Eigenwerten.



Wir haben jetzt unabhängige Spaltenmuster v_i und zugehörige Eigenwerte λ_i . Nächste Frage: Warum gilt $\lambda_i = \sigma_i^2$?

Warum gilt $\lambda_i = \sigma_i^2$?

Aus dem Spektralsatz kennen wir jetzt die Spaltenmuster v_i :

$$A^T A v_i = \lambda_i v_i.$$

Jetzt prüfen wir die Norm der Höhenantwort dieses gefundenen Musters im Originalbild A .

Für ein gefundenes Spaltenmuster v_i messen wir:

$$\|A v_i\|^2.$$

Aus der vorherigen Umformung wissen wir:

$$\|A v_i\|^2 = v_i^T A^T A v_i.$$

Jetzt setzen wir die Eigenvektorgleichung ein:


$$\|A v_i\|^2 = v_i^T (\lambda_i v_i) = \lambda_i (v_i^T v_i).$$

Da v_i normiert ist, gilt:

$$v_i^T v_i = 1, \quad \|A v_i\|^2 = \lambda_i.$$

Damit ist der Eigenwert λ_i das **Quadrat des zugehörigen Singulärwerts**.

$$\lambda_i = \|A v_i\|^2, \quad \sigma_i = \|A v_i\| = \sqrt{\lambda_i}.$$



Merke: $\lambda_i = \sigma_i^2$ und $\sigma_i = \|A v_i\|$. Als Nächstes fehlt noch die Höhenverteilung u_i .

Vom Spaltenmuster zur Höhenverteilung

Aus der letzten Folie kennen wir:

- v_i : Muster über die Spalten
- σ_i : Singulärwert des Musters

Für den vollständigen Baustein fehlt:

- u_i : Verteilung über die Bildzeilen

$$B_i = \sigma_i u_i v_i^T.$$

Leitfrage: In welchen Bildzeilen kommt v_i vor?

Dazu benutzen wir wieder das Originalbild A :

$$A v_i.$$


Das ist die **Höhenantwort**: ein Wert pro Bildzeile.

$$\|A v_i\| = \sigma_i.$$

Also enthält $A v_i$ die Höhenform und den Singulärwert als Skalierung. Für die SVD trennen wir beides:

$$A v_i = \sigma_i u_i, \quad u_i = \frac{A v_i}{\sigma_i} \quad (\sigma_i > 0).$$

Durch das Teilen durch σ_i bleibt die Form über die Höhe erhalten; die Skalierung durch den Singulärwert wird entfernt.



Die Zahlen dienen nur zur Veranschaulichung. In der echten SVD sind v_i und u_i normierte Vektoren.

Aus drei Teilen wird ein Bildbaustein

Letzte Folie:

$$u_i = \frac{Av_i}{\sigma_i}.$$

Umgestellt:

$$Av_i = \sigma_i u_i.$$

Das heißt: Die Höhenantwort des Spaltenmusters besteht aus **Singulärwert** mal **normierter Höhenverteilung**.

Damit kennen wir alle drei Teile:


$$B_i = \sigma_i u_i v_i^T.$$

- v_i^T : Muster über die Spalten
- u_i : Verteilung über die Bildzeilen
- σ_i : Singulärwert des Bausteins

Das äußere Produkt $u_i v_i^T$ macht daraus eine 2D-Bildschicht.

$$\sigma_i \times u_i \times v_i^T = B_i$$

Singulärwert $\times$ Höhenverteilung $\times$ Spaltenmuster



Aus der Kernbeziehung $Av_i = \sigma_i u_i$ wird mit v_i^T der Matrixbaustein $B_i = \sigma_i u_i v_i^T$.

Merke: Höhenantwort plus Spaltenmuster ergibt die vollständige Bildschicht. Damit kennen wir wieder die Bausteinform aus dem Anfang der Herleitung.

Alle Bildbausteine zusammen ergeben das Bild

Auf der letzten Folie hatten wir einen einzelnen Bildbaustein:

$$B_i = \sigma_i u_i v_i^T.$$

Das ganze Bild entsteht, wenn wir alle nichtverschwindenden Bausteine addieren:

$$A = B_1 + B_2 + \dots + B_r$$

also:

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T.$$

r ist die Anzahl der positiven Singulärwerte:

$$r = \text{rang}(A).$$

Wenn $\sigma_i = 0$, dann ist $\sigma_i u_i v_i^T = 0$. Dieser Baustein trägt nichts zum Bild bei.

Die Summe lässt sich kompakt als Matrixprodukt schreiben:

$$U_r = (u_1, \dots, u_r), \quad V_r = (v_1, \dots, v_r).$$


[Math Processing Error]

$$A = U_r \Sigma_r V_r^T.$$

- U_r : Höhenverteilungen
- Σ_r : Singulärwerte
- V_r^T : Spaltenmuster

Einzelne 6×6-Bildbausteine

$$B_i = \sigma_i u_i v_i^T$$



Alle kleinen Matrizen sind 6×6. Summe der Bausteine und Matrixform beschreiben dieselbe Rekonstruktion.

Warum können wir kleine Bausteine weglassen?

Aus der letzten Folie wissen wir:

$$A = \sum_{i=1}^r \sigma_i u_i v_i^T.$$

Das Bild ist also eine Summe sortierter Bildbausteine.

Für Kompression behalten wir nur die ersten k Bausteine:

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T.$$

Die weggelassenen Bausteine bilden den Fehler:

$$A - A_k = \sum_{i=k+1}^r \sigma_i u_i v_i^T.$$

Weil die Singulärwerte absteigend sortiert sind, lassen wir genau die schwächsten Bildschichten weg.

Der Singulärwert eines Bausteins ist σ_i .

Weil die SVD-Bausteine orthogonal zueinander sind, addieren sich die Quadrate ihrer Singulärwerte sauber:

$$\|A - A_k\|_F^2 = \sum_{i=k+1}^r \sigma_i^2.$$

Der Fehler besteht genau aus der Energie der weggelassenen Bildschichten.

Wenn die weggelassenen σ_i klein sind, ist auch der Rekonstruktionsfehler klein.


Eckart-Young-Mirsky sagt zusätzlich:

$$\|A - A_k\|_F \leq \|A - B\|_F \quad \text{für alle } \text{rang}(B) \leq k.$$

Also ist A_k die beste Rang- k -Näherung im Frobeniusfehler.


Bausteine sind nach Singulärwerten sortiert

$$\sigma_1 \geq \sigma_2 \geq \sigma_3 \geq \sigma_4 \geq \sigma_5 \geq \dots$$



Kleine $\sigma_i \rightarrow$ schwache Bildschichten $\rightarrow$ kleiner Fehler

Was bleibt von der SVD hängen?



Kleine $\sigma_i \rightarrow$ schwache Bausteine. Für Kompression behalten wir die ersten k .

Baustein

$$B_i = \sigma_i u_i v_i^T$$

Singulärwert $\times$ Höhenverteilung $\times$ Spaltenmuster

Sortierung

$$\sigma_1 \geq \sigma_2 \geq \dots$$

Große σ_i bedeuten wichtige Bildanteile.

Kompression

$$A_k = \sum_{i=1}^k \sigma_i u_i v_i^T$$

Wir behalten die stärksten Bausteine.

Die SVD macht sichtbar, welche Bildstrukturen wichtig sind, und erlaubt dadurch eine kontrollierte Kompression.

Quellen

- [**Bae16**] Bärwolff, G. *Numerik für Ingenieure, Physiker und Informatiker*. Springer, 2. Aufl., 2016 (Kap. 3).
- [**Bas20**] Bashier, E. *Practical Numerical and Scientific Computing with MATLAB and Python*. CRC Press, 2020 (Kap. 1).
- [**Kar15**] Karpfinger, C. *Höhere Mathematik in Rezepten*. Springer, 2. Aufl., 2015 (Kap. 42.3–42.4).
- [**Kel21**] Keller, A. *Aufgaben und Lösungen zur Mathematik für den Studienstart*. Springer, 2021 (Kap. 25.8–25.9).
- [**Kel24**] Keller, A. *Handout Eigenwerte, Spektralsatz, Singular Value Decomposition und Least-Squares*. THWS, 2024.
- [**Mol04**] Moler, C. B. *Numerical Computing with MATLAB*. SIAM, 2004 (Kap. 10.1–10.4 und 10.11).
- [**TB22**] Trefethen, L. und Bau, D. *Numerical Linear Algebra*. SIAM, 2022.
- [**Str10**] Strang, G. *Wissenschaftliches Rechnen*. Springer, 2010 (Kap. 1).

Eigenständigkeitserklärung

Bei der Erstellung dieser Themenausarbeitung wurden KI-gestützte Werkzeuge gemäß der KI-Leitlinie Hochschullehre Bayern wie folgt eingesetzt:

KI-Werkzeug	Einsatzzweck
Claude (Anthropic)	Strukturierung und sprachliche Überarbeitung der Folien
Claude (Anthropic)	Erzeugung der Python-Skripte für die generierten Visualisierungen
Claude (Anthropic)	Unterstützung bei der Python-Implementierung der SVD-Bildkompression

Hiermit versichere ich, dass ich die vorliegende Arbeit eigenständig verfasst und keine anderen als die angegebenen Quellen und Hilfsmittel verwendet habe. Alle übernommenen Inhalte sowie mit Unterstützung von KI generierten Inhalte wurden entsprechend den anerkannten wissenschaftlichen Grundsätzen oder entsprechend der Regelungen zur Kennzeichnung von KI-Inhalten kenntlich gemacht. Ausgenommen von der Kenntlichmachung sind orthografische oder grammatikalische Korrekturen, Übersetzungen sowie nicht-sinnverändernde Verbesserungen von Formulierungen. Ich bin mir bewusst, dass mit KI generierte Texte keine Garantie für die Qualität von Inhalten und Text bieten. Daher erkläre ich, dass ich KI-Werkzeuge lediglich als Hilfsmittel genutzt habe, die von KI generierten Inhalte kritisch überprüft habe und mein eigenständiger sowie kreativer Einfluss in dieser Arbeit überwiegt. Ich versichere, dass ich Inhalte meiner Arbeit vollständig verstanden habe und selbstständig vertreten kann. Ich versichere, dass ich ausschließlich KI-Werkzeuge verwendet habe, deren Nutzung vom Prüfer oder der Prüferin als Hilfsmittel zugelassen wurden.